


UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE ELECTRÓNICA
VALPARAÍSO – CHILE



Diseño y Desarrollo de Plataforma de Apreciación Artística para Personas con Discapacidad Visual

Alexey Nikolay Mitjaew Hupat

Memoria de Titulación para optar al título de Ingeniero Civil Telemático

Profesor Guía:

Patricio Olivares Roncagliolo

Profesor Correferente:

Nicolás Torres Rudloff

Diciembre 2025

Agradecimientos

A mi familia,
mi perro Elvis
y el buen café.

Resumen

Este documento expone el desarrollo de una plataforma accesible de apreciación artística para público con discapacidad visual. La propuesta consiste en transformar obras en representaciones sonoras multifacéticas, integrando descripciones narrativas detalladas, contexto histórico-artístico y atmósferas auditivas por medio del uso de modelos multi-modales de lenguaje, sistemas de síntesis de voz y modelos de generación sonora basada en texto.

La solución expuesta propone facilitar el acceso al arte mediante una experiencia adaptada, con el objetivo de ofrecer alternativas de apreciación sensorial para personas con discapacidad visual.

Palabras clave: *Accesibilidad / Arte inclusivo / Inteligencia artificial / Sonificación*

Lista de Figuras

Figura 1	Codificación Multimodal Llama V4	13
Figura 2	Arquitectura de Modelo Tacotron 2	15
Figura 3	Arquitectura de Modelo AudioLDM	16
Figura 4	Arquitectura General de Sistema	17
Figura 5	Segmentación por Cuadrantes de Obra «El Aquelarre»	19
Figura 6	Modelo de Datos de la Plataforma	20
Figura 7	Flujo de Navegación Frontend	21
Figura 8	Documentación Swagger de la API	22
Figura 9	Frontend de la Plataforma	23
Figura 10	Funcionalidad de Búsqueda en Frontend	23
Figura 11	Obra «El Aquelarre» de Francisco de Goya	24

Lista de Tablas

Tabla 1	Comparación del Estado del Arte en Accesibilidad Artística	12
Tabla 2	Muestra de Elementos Detectados en Obra «El Aquelarre»	27

Contenidos

I)	Introducción	6
I.1)	Objetivo General	7
I.2)	Objetivos Particulares	7
I.3)	Estructura	7
II)	Marco Teórico	8
II.1)	Modelos de Lenguaje Multimodales	8
II.2)	Modelos Generativos de Audio	8
II.3)	Modelos de Text to Speech	9
II.4)	Estándares de Accesibilidad	9
III)	Estado del Arte	10
III.1)	Tecnologías y Prácticas en Accesibilidad Cultural y Artística	10
III.1.a	Accesibilidad cultural tradicional y práctica museográfica	10
III.1.b	Proyectos y colectivos de accesibilidad en arte	10
III.1.c	Investigación académica y tecnologías emergentes	11
III.1.d	Plataformas digitales de difusión cultural	11
III.2)	Comparación Cruzada de Alternativas	12
III.3)	Modelos de Lenguaje Multimodales	13
III.4)	Modelos de Texto a Voz	15
III.5)	Modelos Generativos de Ambiente Sonoro	16
IV)	Desarrollo de la Plataforma	17
IV.1)	API Gateway	17
IV.1.a	Generador de Audio Descriptivo	18
IV.1.b	Generador de Narraciones de Contexto	18
IV.1.c	Generador de Sonidos Ambientales	19
IV.1.d	Catálogo de Obras/Imágenes	20
IV.2)	Frontend	21
IV.3)	Limitaciones	21

V)	Resultados	22
V.1)	API Gateway	22
V.2)	Frontend	23
V.3)	Módulos Generativos	24
V.3.a	Generación de Texto de Audio Descriptivo	25
V.3.b	Generación de Texto de Narraciones de Contexto	26
V.3.c	Generador de Sonidos Ambientales	27
V.3.d	Audio Generado con TTS	28
VI)	Conclusiones	29
VII)	Bibliografía	30
VIII)	Anexo	33
VIII.1)	Utilidades Generales	33
VIII.2)	Pipeline de Extracción de Fuentes	34
VIII.3)	Generación de Contenido General	35
VIII.4)	Utilidades Generales de Procesamiento de Imágenes	39
VIII.5)	Generación de Audio Descriptivo	40
VIII.6)	Narrador de Contexto	41
VIII.7)	Generación de Sonidos Ambientales	42
VIII.8)	Text to Speech	45

I) Introducción

El acceso equitativo al arte constituye un componente esencial del desarrollo cultural y social, sin embargo, las personas con discapacidad visual continúan enfrentando barreras significativas para disfrutar de obras visuales en condiciones comparables al resto del público. Aunque las tecnologías de apoyo han avanzado, aún existe una brecha entre la experiencia estética que ofrecen los museos y plataformas digitales tradicionales y las necesidades sensoriales de quienes no pueden percibir elementos visuales directamente.

En este contexto, la inteligencia artificial emerge como una oportunidad para reimaginar la forma en que se transmite el contenido artístico, permitiendo crear experiencias que integren narrativa, sonido y contextualización cultural.

Este proyecto desarrolla una alternativa de accesibilidad para consumo de contenido orientado a personas con discapacidad visual. En particular se plantea utilizar modelos de lenguaje multimodales, sistemas de síntesis de voz y modelos generativos de audio para una pipeline integrada de producción de piezas de audio que comprendan desde narraciones habladas hasta paisajes sonoros que representen los contenidos de las obras.

Dado que esta investigación se fundamenta en los principios de accesibilidad universal y diseño inclusivo, el acceso al contenido se implementará a través de un cliente web que considere estándares establecidos en la materia.

I.1) Objetivo General

Mejorar la experiencia estética y promover la accesibilidad universal a las obras de arte para personas con discapacidad visual mediante el diseño e implementación de una plataforma accesible que utilice inteligencia artificial para transformar automáticamente imágenes de obras artísticas en paisajes sonoros y descripciones auditivas significativas.

I.2) Objetivos Particulares

- **Proveer un catálogo curado de obras de dominio público**, basado en fuentes autoritativas y verificadas.
- **Generar audios descriptivos** que contengan una representación objetiva y comprensible del contenido visual de las obras.
- **Crear audios narrativos con contenido histórico/biográfico** fundamentadas en fuentes reconocidas, que contextualizen la obra, su autor(a) y su relevancia artística.
- **Producir ambientes sonoros inmersivos** que recreen la atmósfera de las obras con piezas de audio evocativo y coherente con el contenido representado.
- **Diseñar una interfaz centrada en accesibilidad**, que habilite una experiencia de navegación cómoda para personas con discapacidad visual.

I.3) Estructura

El presente informe incluye:

- *Revisión del estado del arte sobre modelos generativos y estándares de accesibilidad.*
- *Evaluación del marco teórico utilizado para el desarrollo de la plataforma.*
- *Descripción de la plataforma desarrollada a nivel de componentes.*
- *Revisión de resultados obtenidos y conclusiones al respecto.*

II) Marco Teórico

II.1) Modelos de Lenguaje Multimodales

Los modelos de lenguaje (LLMs, por sus siglas en inglés) representan sistemas computacionales diseñados para procesar, comprender y generar texto en lenguaje natural mediante arquitecturas basadas en aprendizaje profundo. Estos modelos, entrenados en vastos corpus textuales, capturan patrones lingüísticos, semánticos y contextuales, permitiendo tareas como la traducción automática, la generación de respuestas coherentes o el análisis de sentimientos. Su evolución ha dado paso a los modelos de lenguaje multimodales, los cuales extienden estas capacidades al integrar contenido multimedial como imágenes y audio.

Estos nos permiten generar descripciones detalladas de escenas, objetos o composiciones artísticas, traduciendo elementos visuales en narrativas estructuradas. Además, su capacidad multimodal se puede utilizar para procesar entradas de voz y participar en flujos conversacionales voz a voz, facilitando interacciones más naturales y accesibles. Esta convergencia de modalidades (texto, imagen y sonido) facilita la creación de sistemas más ricos y adaptables, capaces de ofrecer interpretaciones contextualizadas y personalizadas según las necesidades de percepción del usuario.

II.2) Modelos Generativos de Audio

Los modelos generativos de audio representan sistemas capaces de crear sonidos y música a partir de prompts de texto. Estos modelos, basados en arquitecturas de aprendizaje profundo, pueden sintetizar desde sonidos de animales y objetos (como el canto de pájaros o el sonido de una tormenta) hasta composiciones musicales, ajustándose a estilos, géneros o emociones específicas. Su funcionamiento se sustenta en la interpretación de instrucciones textuales o parámetros acústicos, permitiendo generar audio coherente y contextualizado sin necesidad de muestras preexistentes.

II.3) Modelos de Text to Speech

Los modelos de *Text to Speech* (TTS) constituyen sistemas computacionales que transforman texto escrito en habla sintética mediante técnicas de procesamiento de lenguaje natural y síntesis de voz. Los modelos de estado del arte están fundamentados en arquitecturas de aprendizaje profundo (incuyendo por lo general el uso de arquitecturas *Difussion* y *Transformers*), analizan la estructura lingüística, semántica y prosódica del input textual para generar audio con entonación, ritmo y naturalidad cercanos a la expresión humana. Su aplicación abarca desde asistentes virtuales y herramientas de accesibilidad hasta sistemas de comunicación aumentativa, permitiendo la generación de voces personalizadas, multilingües y adaptadas a contextos específicos, lo que facilita la interacción con usuarios en entornos digitales y físicos.

II.4) Estándares de Accesibilidad

Los estándares de accesibilidad proporcionan el marco normativo que guía el diseño de interfaces inclusivas, asegurando que los contenidos digitales sean utilizables por personas con diversas capacidades sensoriales, motoras o cognitivas. Entre los más relevantes se encuentran las Pautas de Accesibilidad para el Contenido Web (WCAG) [1], que establecen criterios relacionados con la perceptibilidad, operabilidad, comprensibilidad y robustez de los sistemas web. En el contexto chileno, estas directrices se integran mediante la Ley N.º 20.422 [2], que regula la igualdad de oportunidades e incorpora exigencias específicas para tecnologías asistivas. La plataforma desarrollada en este proyecto adopta estos lineamientos para garantizar compatibilidad con lectores de pantalla, navegación por teclado, descripciones alternativas, controles auditivos accesibles y una estructura de interacción que facilite la exploración autónoma.

El cumplimiento de estos estándares es esencial para asegurar que la solución propuesta sea inclusiva y centrada en las necesidades de los usuarios objetivo.

III) Estado del Arte

III.1) Tecnologías y Prácticas en Accesibilidad Cultural y Artística

La accesibilidad al arte ha sido abordada desde múltiples perspectivas, incluyendo prácticas museográficas tradicionales, tecnologías asistivas, proyectos artísticos inclusivos y desarrollos experimentales basados en inteligencia artificial. Su evolución reciente ha estado marcada por la incorporación de herramientas digitales y enfoques multimodales que buscan ampliar el acceso a la experiencia artística para personas con discapacidades sensoriales.

III.1.a Accesibilidad cultural tradicional y práctica museográfica

Las instituciones culturales han implementado históricamente recursos de accesibilidad como audiodescripciones, maquetas táctiles, textos en braille y recorridos guiados adaptados. Estas prácticas están documentadas en guías oficiales de accesibilidad para museos, donde se destacan las audioguías adaptadas y las signoguías como mecanismos fundamentales para la inclusión cultural [3].

A nivel institucional, también se han desarrollado programas específicos de accesibilidad multimedia. Un ejemplo relevante es el programa **Experiencias multimediales MAC para la accesibilidad**, impulsado por el Museo de Arte Contemporáneo de la Universidad de Chile, el cual incorpora audioguías, cápsulas audiovisuales subtituladas y contenidos en lengua de señas chilena para ampliar el acceso a sus exposiciones [4].

III.1.b Proyectos y colectivos de accesibilidad en arte

Existen iniciativas orientadas específicamente a la mediación artística inclusiva. El proyecto **Audioguiarte** desarrolla audioguías personalizadas y recorridos accesibles, combinando narrativas sonoras y contenidos adaptados para públicos diversos [5].

De forma complementaria, colectivos como **MiméticasLab** exploran la recreación de obras artísticas mediante formatos táctiles y multisensoriales, empleando tecnologías de fabricación digital como impresión 3D para facilitar el acceso de personas con discapacidad visual [6].

Un caso documentado de implementación museográfica accesible se observa en el Museo Provincial de Bellas Artes Emilio Caraffa (Argentina), donde se desarrolló una sala accesible para personas ciegas mediante códigos QR, audiodescripciones y paisajes sonoros, permitiendo una experiencia estética alternativa [7].

III.1.c Investigación académica y tecnologías emergentes

En el ámbito académico, se han propuesto sistemas que traducen representaciones visuales a formatos multimodales accesibles. El proyecto **MAIDR** plantea la representación multimodal de visualizaciones estadísticas mediante texto, audio y otros canales, con el objetivo de facilitar su interpretación por parte de personas con discapacidad visual [8]. Asimismo, investigaciones recientes exploran la generación automática de música a partir de obras pictóricas, buscando traducir atributos visuales y emocionales en experiencias sonoras accesibles [9].

Estas propuestas, si bien prometedoras, se presentan mayoritariamente como prototipos experimentales sin una integración directa en plataformas de uso cultural generalizado.

III.1.d Plataformas digitales de difusión cultural

Plataformas digitales como **Smartify** y **Google Arts & Culture** han ampliado el acceso al patrimonio artístico mediante la digitalización de colecciones y el uso de dispositivos móviles para contextualizar obras de arte. **Smartify** permite el reconocimiento de obras mediante imágenes y la entrega de información textual y auditiva asociada [10].

Por su parte, **Google Arts & Culture** ofrece recorridos virtuales y colecciones digitales de museos de todo el mundo, facilitando el acceso remoto al arte, aunque sin un foco específico en accesibilidad profunda o personalización multimodal [11].

III.2) Comparación Cruzada de Alternativas

Categoría	Ejemplos / Iniciativas	Modalidades	Limitaciones
Accesibilidad museo-gráfica tradicional	<ul style="list-style-type: none">• Audioguías• Signoguías• Braille	<ul style="list-style-type: none">• Audio• Táctil• Texto	Escalabilidad limitada y alta dependencia de intervención humana
Programas institucionales	Experiencias multimediales (MAC)	<ul style="list-style-type: none">• Audio• Video• Lengua de señas	Alcance restringido a exposiciones específicas
Proyectos inclusivos independientes	Audioguiarte	Audio narrativo	No universalizado ni automatizado
Fabricación digital accesible	MiméticasLab	<ul style="list-style-type: none">• Táctil• Multisensorial	Requiere recursos físicos y producción manual
Investigación académica	MAIDR, arte a música	<ul style="list-style-type: none">• Texto• Audio	Prototipos experimentales sin despliegue productivo
Plataformas digitales generalistas	<ul style="list-style-type: none">• Smartify• Google Arts & Culture	<ul style="list-style-type: none">• Imagen• Texto• Audio	Baja personalización orientada a accesibilidad

Tabla 1: Comparación del Estado del Arte en Accesibilidad Artística

A pesar de los avances en tecnologías de accesibilidad artística, persiste una brecha significativa en la integración de flujos automatizados multimodales para la producción de contenido. Las soluciones actuales suelen requerir procesos manuales o semiautomáticos, donde la generación de descripciones auditivas, representaciones táctiles o traducciones sonoras se realiza de forma aislada, sin una coordinación eficiente entre modalidades. Esta fragmentación limita la escalabilidad y la coherencia en la producción de experiencias artísticas accesibles, dificultando su adopción masiva en entornos culturales.

III.3) Modelos de Lenguaje Multimodales

Durante los últimos años los modelos multimodales de lenguaje han experimentado avances significativos, integrando capacidades de procesamiento de texto, imagen, audio y video. Este progreso ha sido impulsado por arquitecturas unificadas basadas en Transformers que permiten compartir un espacio de representación común entre modalidades. Avances como los *Vision-Language Encoders (VLMs)* [12] y la *Tokenización Unificada* [13] han permitido integrar imágenes y texto como secuencias compatibles.

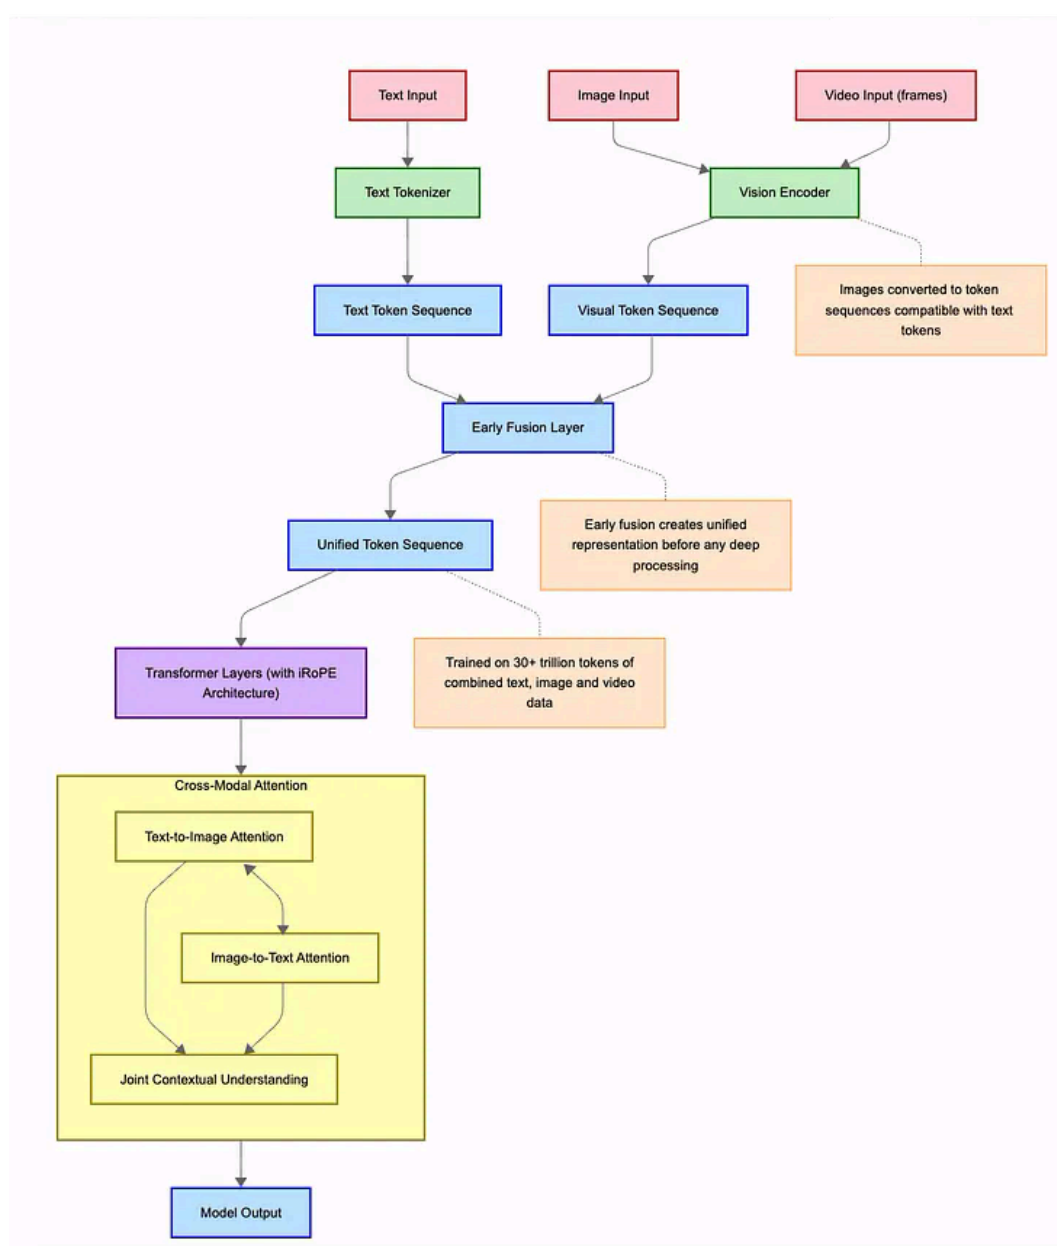


Figura 1: Codificación Multimodal Llama V4

Algunos modelos destacados a la fecha son:

- **Llama v4 (Meta)** [14]: Modelo multimodal con pesos liberados capaz de elaborar descripciones semánticas de imágenes por medio de codificación con *MetaCLIP*.
- **GPT-4o (OpenAI)** [15] y **Gemini 1.5 (Google)** [16]: Modelos con integración nativa de texto, imagen y audio. Sin pesos liberados.
- **DeepSeek-OCR (DeepSeek)** [17]: Modelo multimodal de código abierto especializado en OCR y documentos visuales. Usa compresión óptica 2D para procesar contextos largos con alta precisión y bajo uso de tokens.

La opción preferida para las pruebas de concepto referidas en este trabajo fue *Llama v4* [14]. La codificación multimodal este modelo (Figura 1) puede entenderse como una arquitectura de fusión temprana en la que el texto, las imágenes y los fotogramas de video se convierten primero en secuencias de tokens compatibles y luego se unifican antes del procesamiento profundo con transformadores. Al alinear los tokens visuales con los tokens textuales desde la etapa de entrada, el modelo permite representaciones compartidas que facilitan la interacción entre modalidades a lo largo de todas las capas del transformer, y no solo al final. La atención contextual (o atención multimodal) opera entonces de forma bidireccional: el texto atiende a las características visuales y los tokens visuales atienden al contexto lingüístico, lo que favorece el razonamiento conjunto y el anclaje semántico. Estas características facilitan uno de nuestros principales casos de uso: la interpretación cualitativa de contenido de imágenes mediada por instrucciones de texto.

III.4) Modelos de Texto a Voz

En los últimos años, arquitecturas basadas en RNNs han ganado relevancia. Estos modelos, generalmente ligeros en cantidad de parámetros, son razonables de autohostear con GPUs de grado consumidor e incluso (en algunos casos) directo en CPU a coste de mayor tiempo de inferencia. Algunos aportes importantes son

- **Tacotron 2** [18]: Modelo de síntesis de voz basado en una arquitectura encoder-decoder con mecanismo de atención, en el cual una red recurrente genera espectrogramas mel de manera autoregresiva a partir de secuencias de texto o fonemas, utilizando posteriormente un vocoder neural para la generación de la señal de audio (Figura 2).
- **VITS** [19]: Modelo de síntesis de voz end-to-end que combina un encoder de texto, un modelo variacional con normalizing flows y un generador adversarial para producir directamente la forma de onda de audio, incorporando un mecanismo de alineamiento monótonico latente para modelar la correspondencia entre texto y audio.
- **StyleTTS2** [20]: Introduce una arquitectura de síntesis de voz multi-componente que emplea encoders separados para contenido lingüístico y estilo, junto con un generador adversarial, permitiendo modelar variaciones de prosodia y timbre a través de representaciones latentes explícitas durante el proceso de síntesis.

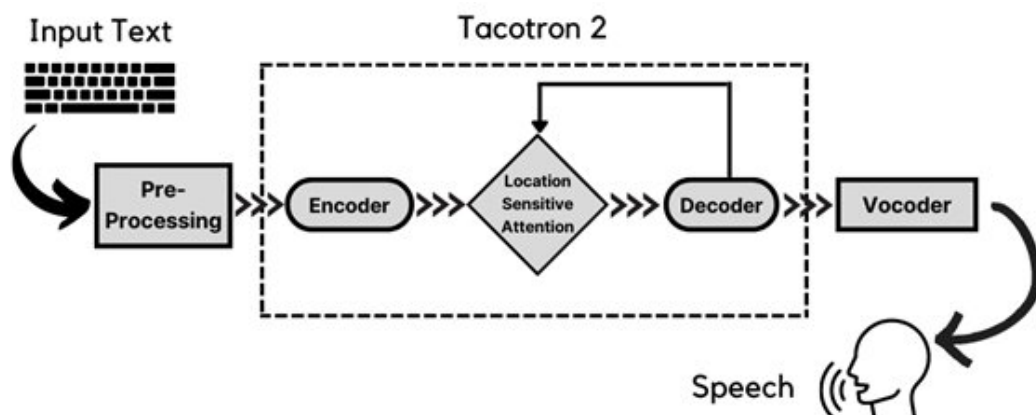


Figura 2: Arquitectura de Modelo Tacotron 2

Kokoro TTS [21], basado en *StyleTTS2* [20], destaca por generar voces de alta calidad con 82 millones de parámetros, actualmente soporta 3 voces preentrenadas para el español.

III.5) Modelos Generativos de Ambiente Sonoro

La generación de ambientes sonoros de alta calidad sigue en fase experimental, sin soluciones comerciales consolidadas. Modelos como CLAP permiten mapear texto y audio en un espacio semántico compartido, aunque no generan audio directamente.

Entre los modelos inicialmente considerados para la plataforma se encuentran:

- **I Hear Your True Colors** [22]: La arquitectura propuesta en este paper combina el uso de un VQVAE, transformers y CLIP. El VQVAE extrae representaciones jerárquicas como secuencias discretas, los transformers las modelan de forma autorregresiva y CLIP alinea el audio con lo visual. Aunque el código es abierto, no existen fuentes públicas de pesos preentrenados ni versiones comerciales por parte de proveedores externos.
- **AudioLDM** [23]: Utiliza un modelo de difusión latente para generar espectrogramas de audio condicionados por texto. El sistema emplea un autoencoder variacional (VAE) para proyectar los espectrogramas al espacio latente, donde un modelo de difusión tipo U-Net aprende el proceso generativo. La condición textual se incorpora mediante embeddings CLAP [24], lo que mejora significativamente la alineación semántica entre descripciones textuales y el contenido sonoro generado. Tras el proceso de difusión, las representaciones latentes se decodifican nuevamente a audio (Figura 3). Presenta resultados prometedores en coherencia semántica y diversidad acústica. El modelo preentrenado se encuentra disponible con pesos abiertos.

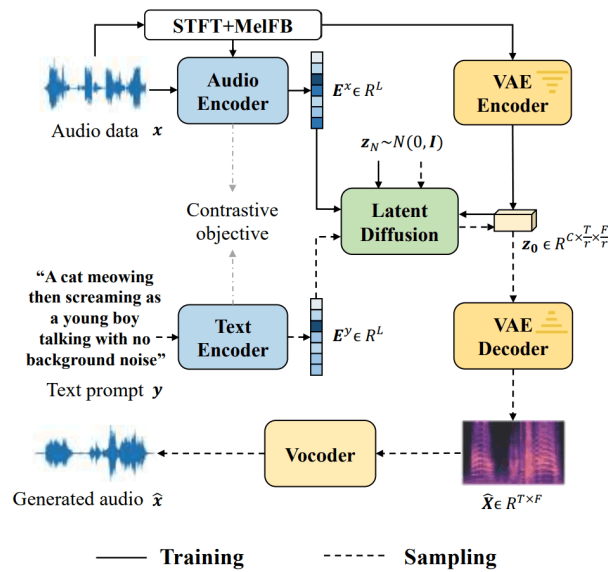


Figura 3: Arquitectura de Modelo AudioLDM

IV) Desarrollo de la Plataforma

La arquitectura propuesta se fundamenta en un modelo cliente-servidor, decisión que responde a la necesidad de desacoplar las interfaces de usuario de los procesos computacionalmente intensivos asociados a la inferencia de modelos de aprendizaje automático y al procesamiento multimedia. Este enfoque permite, por un lado, mantener una experiencia de usuario fluida en dispositivos con capacidades limitadas y, por otro, facilitar la escalabilidad y mantenibilidad del sistema.

IV.1) API Gateway

Se incorpora una API Gateway como componente central de la arquitectura. La elección de una API Gateway se justifica por tres motivos principales:

- Centralizar el acceso a funcionalidades heterogéneas bajo una interfaz uniforme, reduciendo la complejidad del frontend
- Aislar los servicios internos del sistema, permitiendo su evolución independiente
- Concentrar las tareas de mayor costo computacional en un entorno controlado, optimizado para la ejecución de modelos de IA.

Además, se desarrolla un *frontend* que aplica principios de accesibilidad, con especial atención a las necesidades de usuarios con discapacidad visual.

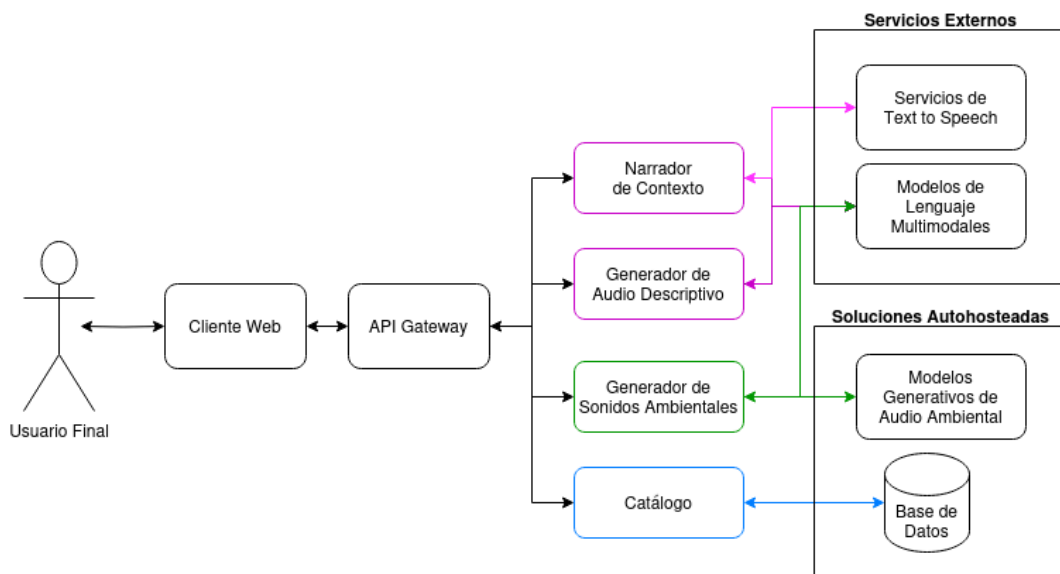


Figura 4: Arquitectura General de Sistema

Se decide utilizar Django como framework por su capacidad para agilizar el desarrollo de APIs robustas mediante su sistema de ORM, su arquitectura basada en modelos-vistas-plantillas (MVT) y su ecosistema de paquetes especializados. Además, su soporte integrado para autenticación, manejo de rutas y middleware facilita la implementación de políticas de seguridad y gestión de solicitudes, aspectos críticos para en el futuro robustecer nuestro sistema con flujos de administración de contenido.

Nuestra API Gateway se divide en cuatro servicios independientes para garantizar un adecuado encapsulamiento durante el desarrollo de la plataforma (Figura 4). Cada uno de estos servicios corresponde a un módulo débilmente acoplado, asociado a tablas específicas dentro del modelo de datos.

IV.1.a Generador de Audio Descriptivo

Este módulo se encarga de producir descripciones textuales detalladas de los contenidos visuales presentes en las obras. Para ello, emplea modelos de lenguaje multimodales, en particular *Llama V4 Maverick* [14] para evaluar entrada de imágenes y texto.

La imagen se evalúa junto a un *prompt* diseñado para extraer información de los contenidos de la obra, además se añaden instrucciones para mantener una cadencia de redacción fluida (Código 12).

Posteriormente, las descripciones generadas son convertidas a formato de audio mediante sistemas de síntesis de voz (TTS) (Código 18) utilizando *Kokoro 82M* [21].

IV.1.b Generador de Narraciones de Contexto

Este módulo genera narraciones auditivas que contextualizan históricamente cada obra. Para ello, se recopila información de fuentes autoritativas (en este caso, se procesó manualmente un conjunto de datos con artículos de Wikipedia vinculados a cada pieza) (Código 7). A partir de estos datos, se elabora un relato contextualizado y adaptado al caso de uso (Código 13), que posteriormente se convierte en audio mediante modelos de síntesis de voz (Text to Speech) (Código 18).

IV.1.c Generador de Sonidos Ambientales

Este módulo se encarga de la generación de ambientes sonoros que representan los contenidos literales (no abstractos) de sus imágenes de entrada. La heurística utilizada consiste en:

- Dividir el espacio en cuadrantes, en nuestro caso 9 (Código 14), como se puede apreciar en Figura 5.
- Procesar cada cuadrante mediante modelos de lenguaje multimodales (Código 15). Por razones de operatividad con modelos de lenguaje y facilidad de interpretación se decide procesar la salida de esta parte en formato JSON.
- Por cada cuadrante generar una mezcla de sonido integrando todos los elementos detectados en cada respectiva sección (Código 16).



Figura 5: Segmentación por Cuadrantes de Obra «El Aquelarre»

IV.1.d Catálogo de Obras/Imágenes

Se elaboró un conjunto de datos en formato JSON que incluye 30 obras artísticas [25], conteniendo todo el material requerido para generar el contenido de la plataforma. Este dataset incorpora, además, enlaces a los artículos de Wikipedia asociados a cada obra artística para tener referencias autoritativas en la generación de narraciones historicas sobre la producción de las mismas.

Una vez procesado el conjunto de datos, sus campos son expuestos a través de la **API** mediante endpoints específicos. Los datos textuales se almacenan en una base de datos SQLite, mientras que las imágenes y archivos de audio generados se guardan en el sistema de archivos local del backend.

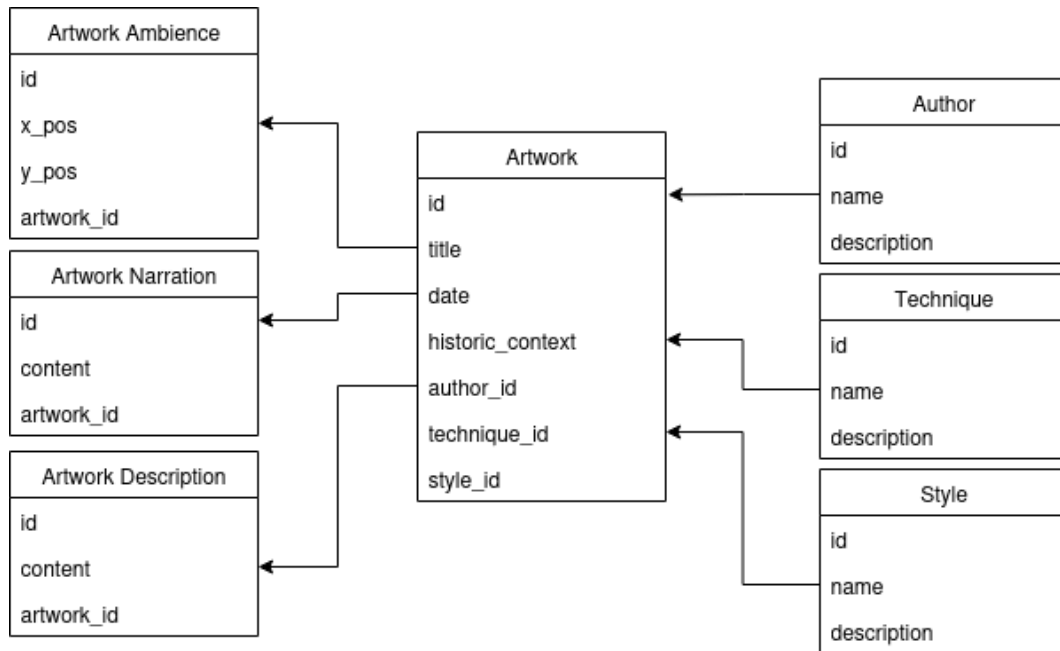


Figura 6: Modelo de Datos de la Plataforma

IV.2) Frontend

El frontend se implementó utilizando NextJS para proporcionar acceso al contenido gestionado por la API Gateway. En su diseño, se incorporaron textos alternativos y etiquetas HTML descriptivas con el objetivo de garantizar una integración completa con herramientas de asistencia para usuarios con discapacidad visual. Asimismo, se desarrolló una interfaz de usuario que facilita la navegación mediante atajos de teclado, optimizando la accesibilidad y usabilidad del sistema.

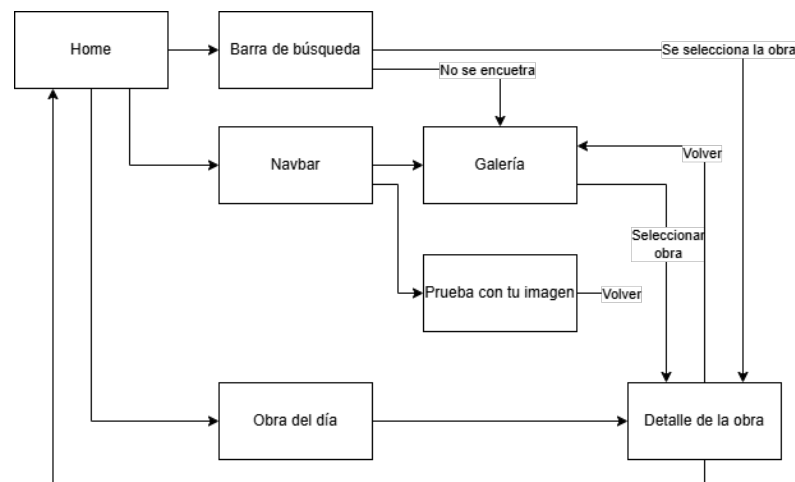


Figura 7: Flujo de Navegación Frontend

IV.3) Limitaciones

Por limitaciones computacionales durante el desarrollo, los módulos no se integraron directamente en la API Gateway. En su lugar, se implementó un prototipo funcional en un cuadernillo Jupyter [26] para validar el diseño y flujo de procesamiento. Esto permitió generar y preprocesar los conjuntos de datos necesarios, que fueron incorporados a la base de datos para su uso en la versión final.

V) Resultados

V.1) API Gateway

El sistema opera correctamente, incluye autodocumentación en *Swagger* y *OpenAPI* y un conjunto completo de operaciones CRUD para todos los módulos de la plataforma.

Debido a las limitaciones computacionales mencionadas previamente, los endpoints solamente habilitan operaciones de lectura y escritura en la base de datos y sistema de archivos para facilitar la subida de elementos preprocesados.

El sistema permite tanto la consulta general de los elementos registrados (obras, autores, períodos históricos, entre otros) como la gestión individual de estos en cada uno de los módulos correspondientes.

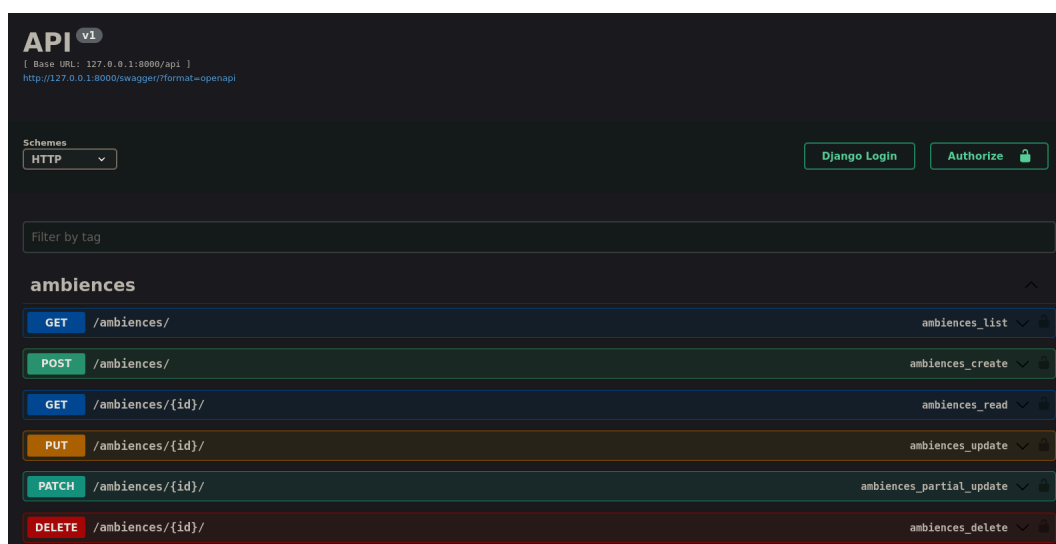


Figura 8: Documentación Swagger de la API

Para garantizar compatibilidad con APIs externas de servicios de cómputo, los datos no estructurados (imágenes y audio) se transmiten codificados en base64. Este método, aunque aumenta el tamaño de los datos enviados (alrededor del 33%), facilita la integración con SDKs de proveedores de inferencia compatibles con la API de OpenAI (como Groq, Novita o TogetherAI). Como mejora futura, se propone adoptar multipart-form-data en la subida y carga de archivos para optimizar el rendimiento de la plataforma.

V.2) Frontend

Aunque no se realizaron pruebas con los usuarios objetivo, se evaluó el funcionamiento de la navegación dentro del sitio mediante herramientas de accesibilidad diseñadas para usuarios con discapacidad visual.

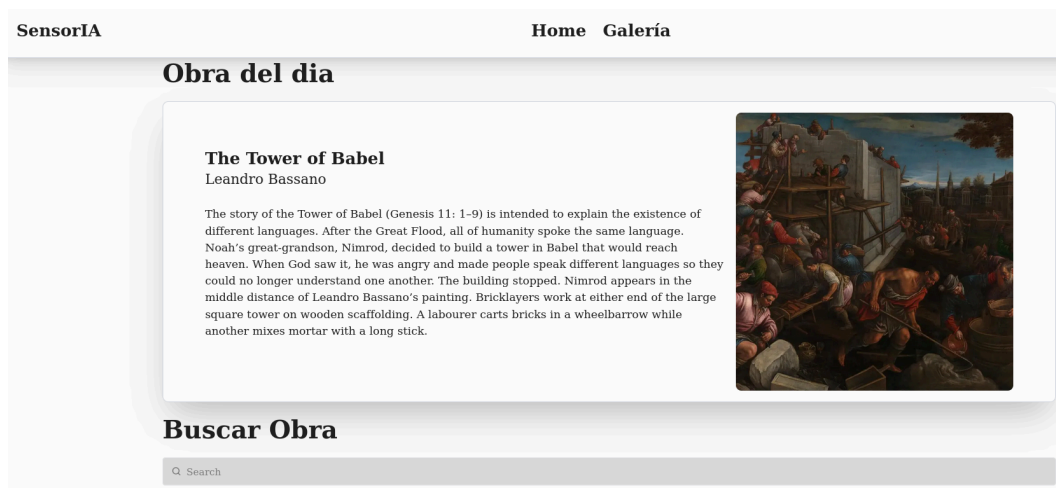


Figura 9: Frontend de la Plataforma

La funcionalidad de navegación implementa correctamente búsquedas por obra, autor, período y técnica. Sin embargo, el sistema emplea un mecanismo de coincidencia de strings que espera un match de acentuación, lo que hace rígida la utilización de la barra de búsqueda.

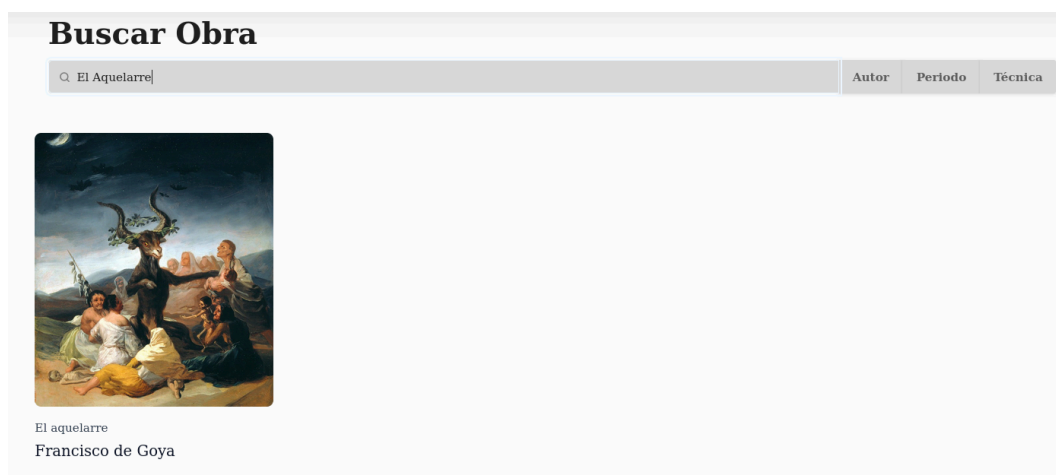


Figura 10: Funcionalidad de Búsqueda en Frontend

La implementación de la visualización de obras y sus módulos asociados opera de manera adecuada, logrando una integración efectiva del contenido audiovisual.

V.3) Módulos Generativos

A continuación se exponen los resultados obtenidos en los módulos generativos de la plataforma. Tal como se indicó en la sección anterior, estas componentes fueron implementadas en un entorno independiente [26] como parte de un desarrollo modular complementario al sistema principal.

Como caso de estudio representativo, se ha seleccionado la obra **El Aquelarre** de Francisco de Goya para ilustrar el funcionamiento de los módulos.



Figura 11: Obra «El Aquelarre» de Francisco de Goya

A continuación, se evalúan los siguientes aspectos:

- La calidad del texto en los módulos de *Audio Descriptivo* y *Narraciones de Contexto*.
- La fidelidad y realismo del audio producido por el *Generador de Sonidos Ambientales*.
- La naturalidad y claridad de la voz sintetizada empleada en las pruebas de concepto.

V.3.a Generación de Texto de Audio Descriptivo

Los resultados obtenidos demuestran una notable correspondencia entre las imágenes de entrada y las descripciones generadas, las cuales mantienen una estructura sintáctica y una cadencia adecuadas para su posterior procesamiento mediante modelos de *Text to Speech*. Este hallazgo sugiere que una estrategia basada en *prompting directo* resulta suficiente para que un modelo de lenguaje multimodal genere descripciones precisas del contenido visual de una obra, sin requerir fuentes autoritativas externas (como artículos de Wikipedia) de referencia para complementar el análisis.

El Aquellare:

En la imagen se puede observar una representación de un ritual o acto de adoración hacia un macho cabrío. La figura del macho cabrío viste una corona de hojas y se encuentra en el centro de la composición. Está rodeado de personas que parecen estar participando en algún tipo de ceremonia.

Al fondo de la escena se puede ver una luna creciente en el cielo nocturno, lo que sugiere que la escena se desarrolla durante la noche. Detrás del macho cabrío hay un grupo de personas vestidas con túnicas, algunas de las cuales tienen la cara cubierta.

La escena general parece representar una temática relacionada con prácticas antiguas o rituales paganos.

Texto 1: Descripción de Obra El Aquellarre de Francisco de Goya

La suficiencia de los modelos de lenguaje sin necesidad de incluir información extraída de fuentes autoritativas contrasta con lo observado en el siguiente módulo.

V.3.b Generación de Texto de Narraciones de Contexto

Como es señalado en Código 13, para evitar alucinaciones y producir información rica en contexto se toma por entrada un artículo de Wikipedia, para el caso ilustrado:

[https://es.wikipedia.org/wiki/El_aquelarre_\(1798\)](https://es.wikipedia.org/wiki/El_aquelarre_(1798))

Una comparación cruzada entre el texto generado y la información contenida en el artículo de Wikipedia demuestra una adecuada correspondencia con la fuente original, logrando transformar el contenido enciclopédico en una narración fluida y de carácter natural.

El pipeline genera narraciones contextuales y evita alucinaciones vistas en prototipos anteriores de este módulo al utilizar consultas directas a modelos de lenguaje.

Un trabajo pendiente es la corrección de casos borde, en particular anglicismos y siglas.

El Aquellare:

En el palacio de recreo de los duques de Osuna, situado en la finca de la Alameda de Osuna, a las afueras de Madrid, Francisco de Goya pintó seis pequeños cuadros entre 1797 y 1798. Uno de ellos, "El aquelarre", es una obra que representa un ritual de brujería presidido por un gran macho cabrío, forma del demonio, rodeado de brujas ancianas y jóvenes que entregan niños, según la superstición de la época, para alimentar al demonio. La escena se desarrolla bajo un cielo nocturno iluminado por la luna, con animales nocturnos volando en el fondo, creando una atmósfera siniestra y oscura.

La serie a la que pertenece "El aquelarre" forma parte de la estética del "sublime terrible", una corriente del prerromanticismo que buscaba generar desasosiego y una sensación de pesadilla en el espectador. Goya estaba trabajando en "Los Caprichos" en ese momento, una obra estrechamente relacionada temáticamente con la serie de cuadros para los duques de Osuna. La brujería era un tema de actualidad entre los ilustrados españoles amigos de Goya, y su interés en este tema se refleja en la ambientación nocturna y los tonos oscuros que predominan en "El aquelarre". La obra forma parte de la colección de la Fundación Lázaro Galdiano, después de ser adquirida por José Lázaro Galdiano en 1928.

Texto 2: Narración de Obra El Aquellarre de Francisco de Goya

V.3.c Generador de Sonidos Ambientales

El proceso de detección de elementos acústicos en la obra presenta un desempeño adecuado, aunque se observan alucinaciones ocasionales en la identificación de componentes específicos, como puede apreciarse en el objeto detectado en segunda imagen de Tabla 2. No obstante, por lo general los elementos detectados mantienen coherencia temática con el contenido representado.



Segmento	Sonidos Generados						
	<table><tr><td>Objeto</td><td>goat bleating</td></tr><tr><td>Fondo</td><td>tree branch creaking, people whispering</td></tr><tr><td>Audio</td><td>https://youtu.be/dqOECGiEiBI</td></tr></table>	Objeto	goat bleating	Fondo	tree branch creaking, people whispering	Audio	https://youtu.be/dqOECGiEiBI
Objeto	goat bleating						
Fondo	tree branch creaking, people whispering						
Audio	https://youtu.be/dqOECGiEiBI						
	<table><tr><td>Fondo</td><td>sand</td></tr><tr><td>Objeto</td><td>puppy sleeping</td></tr><tr><td>Audio</td><td>https://youtu.be/mT7UBvVd9m8</td></tr></table>	Fondo	sand	Objeto	puppy sleeping	Audio	https://youtu.be/mT7UBvVd9m8
Fondo	sand						
Objeto	puppy sleeping						
Audio	https://youtu.be/mT7UBvVd9m8						

Tabla 2: Muestra de Elementos Detectados en Obra «El Aquelarre»

Respecto a la calidad del audio generado se puede decir que, aunque la mayoría de los cuadrantes producen resultados verosímiles y coherentes con las escenas representadas, se observa un grado variable de ruido y artefactos en las mezclas de sonido y se identifican *outliers* donde los ambientes degeneran en ruido. Este comportamiento sugiere limitaciones en la generalización del modelo ante elementos visuales ambiguos y/o composiciones atípicas dentro de las obras.

V.3.d Audio Generado con TTS

La implementación del módulo de Text-to-Speech (TTS) (Código 18) utilizando *Kokoro82M* [21] demostró un nivel de naturalidad adecuado para la generación de audio en español, con una entonación fluida y una pronunciación generalmente clara de los textos descriptivos y narrativos. El tono neutral adoptado por el modelo resulta apropiado para una aplicación de accesibilidad cultural, ya que evita sesgos emocionales que podrían interferir con la percepción objetiva del contenido.

No obstante, se identificaron dificultades específicas en la pronunciación de anglicismos y siglas. Términos y nombres propios de otros idiomas son interpretados con reglas fonéticas del español, generando resultados poco intuitivos para el oyente. Esta limitación sugiere la necesidad de implementar un preprocesamiento que genere descripciones alternativas para dicho contenido (lo que fué implementado parcialmente en las estrategias de prompting de la generación de narraciones de contexto, ver Código 13) o, alternativamente, incorporar un diccionario de excepciones para preservar la inteligibilidad en contextos técnicos.

Los audios generados para la descripción y la narración de «El Aquelarre» se pueden encontrar en los siguientes vínculos:

- **Descripción:** <https://youtu.be/7NwKlbHQKeo>
- **Narración:** <https://youtu.be/P9EOz7Au4ZA>

VI) Conclusiones

Los resultados obtenidos evidencian la utilidad de los modelos de lenguaje multimodales para casos de uso de accesibilidad, al demostrar que estos sistemas son capaces de interpretar de manera integrada información visual y textual y transformarla en representaciones comprensibles para usuarios con discapacidad visual. En particular, la capacidad de los modelos para generar descripciones detalladas y coherentes a partir de imágenes artísticas complejas permite sustituir, en gran medida, la percepción visual directa por una mediación auditiva rica en contenido semántico. Asimismo, la adaptación del estilo narrativo y la cadencia del texto generado facilita su posterior conversión a audio mediante sistemas de síntesis de voz, asegurando una experiencia de escucha fluida y cognitivamente accesible.

Adicionalmente, el uso de modelos multimodales reduce la dependencia de anotaciones manuales extensivas y de metadatos previamente estructurados, lo que representa una ventaja significativa en términos de escalabilidad y mantenimiento de plataformas culturales accesibles. La posibilidad de combinar análisis visual, generación de lenguaje natural y producción de audio en un mismo flujo de procesamiento permite construir soluciones integrales que responden a diversas necesidades de accesibilidad, desde la descripción literal de una obra hasta la contextualización histórica y la recreación de ambientes sonoros. En conjunto, estos resultados respaldan el potencial de los modelos de lenguaje multimodales como herramientas clave para democratizar el acceso al patrimonio cultural, ampliando la inclusión y la participación de públicos tradicionalmente excluidos de la experiencia artística visual.

Por otra parte, la utilización de modelos generativos de audio, si bien presenta limitaciones en su capacidad de generalización y estabilidad, demuestra un alto potencial para la creación de contenido apreciativo e inmersivo; no obstante, los resultados obtenidos ponen de manifiesto la necesidad de incorporar mecanismos de revisión y control de calidad con participación humana (human-in-the-loop) para garantizar la coherencia, fidelidad y utilidad final del contenido generado.

VII) Bibliografía

- [1] W3C, «Web Content Accessibility Guidelines (WCAG) 2.1». [En línea]. Disponible en: <https://www.w3.org/TR/WCAG21/>
- [2] Biblioteca del Congreso Nacional de Chile, «Ley 20.422: Establece normas sobre igualdad de oportunidades e inclusión social de personas con discapacidad». [En línea]. Disponible en: <https://www.bcn.cl/leychile/navegar?idNorma=1010903>
- [3] Ayuntamiento de Málaga, «Guía de accesibilidad en museos». [En línea]. Disponible en: https://www.malaga.eu/recursos/sociales/accesibilidad/guias/ocio_deporte/museos.html
- [4] Museo de Arte Contemporáneo de la Universidad de Chile, «MAC pone en marcha programa de experiencias multimediales para la accesibilidad». [En línea]. Disponible en: <https://mac.uchile.cl/mac-pone-en-marcha-programa-experiencias-multimediales/>
- [5] Audioguiarte, «Proyectos de accesibilidad cultural». [En línea]. Disponible en: <https://audioguiarte.com/proyectos/>
- [6] Ver Sin Límites Accesibilidad, «MiméticasLab: arte accesible para personas con discapacidad visual». [En línea]. Disponible en: <https://versinlimitesaccesibilidad.com/mimeticaslab-arte-accesible-personas-discapacidad-visual/>
- [7] El País, «El arte colectivo de traducir las obras de un museo para ciegos». [En línea]. Disponible en: <https://elpais.com/america-futura/2025-04-19/el-arte-colectivo-de-traducir-las-obras-de-un-museo-para-ciegos.html>
- [8] Y. Wang y others, «MAIDR: Making Statistical Visualizations Accessible with Multimodal Data Representation». [En línea]. Disponible en: <https://arxiv.org/abs/2403.00717>
- [9] H. Zhang y others, «Bridging Paintings and Music: Emotion-Based Music Generation through Paintings». [En línea]. Disponible en: <https://arxiv.org/abs/2409.07827>
- [10] Wikipedia contributors, «Smartify». [En línea]. Disponible en: <https://en.wikipedia.org/wiki/Smartify>
- [11] Google, «Google Arts & Culture». [En línea]. Disponible en: <https://artsandculture.google.com/>

- [12] T. Zhang *et al.*, «Vision-Language-Vision Auto-Encoder: Scalable Knowledge Distillation from Diffusion Models». [En línea]. Disponible en: <https://arxiv.org/abs/2507.07104>
- [13] C. Ma *et al.*, «UniTok: A Unified Tokenizer for Visual Generation and Understanding». [En línea]. Disponible en: <https://arxiv.org/abs/2502.20321>
- [14] Meta, «Llama 4: Multimodal Intelligence». [En línea]. Disponible en: <https://ai.meta.com/blog/llama-4-multimodal-intelligence/>
- [15] OpenAI *et al.*, «GPT-4o System Card». [En línea]. Disponible en: <https://arxiv.org/abs/2410.21276>
- [16] G. Team *et al.*, «Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context». [En línea]. Disponible en: <https://arxiv.org/abs/2403.05530>
- [17] H. Wei, Y. Sun, y Y. Li, «DeepSeek-OCR: Contexts Optical Compression». [En línea]. Disponible en: <https://arxiv.org/abs/2510.18234>
- [18] J. Shen *et al.*, «Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions». [En línea]. Disponible en: <https://arxiv.org/abs/1712.05884>
- [19] J. Kim, J. Kong, y J. Son, «Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech». [En línea]. Disponible en: <https://arxiv.org/abs/2106.06103>
- [20] Y. A. Li, C. Han, V. S. Raghavan, G. Mischler, y N. Mesgarani, «StyleTTS 2: Towards Human-Level Text-to-Speech through Style Diffusion and Adversarial Training with Large Speech Language Models». [En línea]. Disponible en: <https://arxiv.org/abs/2306.07691>
- [21] hexgrad, «Kokoro-82M». [En línea]. Disponible en: <https://huggingface.co/hexgrad/Kokoro-82M>
- [22] R. Sheffer y Y. Adi, «I Hear Your True Colors: Image Guided Audio Generation». [En línea]. Disponible en: <https://arxiv.org/abs/2211.03089>
- [23] H. Liu *et al.*, «AudioLDM: Text-to-Audio Generation with Latent Diffusion Models». [En línea]. Disponible en: <https://arxiv.org/abs/2301.12503>

- [24] B. Elizalde, S. Deshmukh, M. A. Ismail, y H. Wang, «CLAP: Learning Audio Concepts From Natural Language Supervision». [En línea]. Disponible en: <https://arxiv.org/abs/2206.04769>
- [25] Alexey Mitjaew, «Artwork Sensotia Dataset». [En línea]. Disponible en: <https://www.kaggle.com/datasets/alexeymitjaew/artwork-sensotia>
- [26] Alexey Mitjaew, «SensorIA Generation Pipeline». [En línea]. Disponible en: <https://www.kaggle.com/code/alexeymitjaew/sound-generation-pipeline>

VIII) Anexo

VIII.1) Utilidades Generales

En nuestra prueba de concepto se emplearon modelos de lenguaje proporcionados por la plataforma *Groq*, accedidos mediante el cliente de Python de OpenAI. Este estándar es compatible con la mayoría de los proveedores de servicios de inferencia para modelos de lenguaje.

```
1 client = openai.OpenAI(  
2     base_url = "https://api.groq.com/openai/v1",  
3     api_key = user_secrets.get_secret("GROQ_API_KEY")  
4 )
```

Código 3: Inicialización de Cliente

Adicionalmente a lo anterior, se implementó una abstracción genérica para el procesamiento de **prompts**. Esta función permite definir parámetros mediante notación de llaves (por ejemplo, {clave}) para su posterior sustitución mediante argumentos nombrados al invocar la función (ejemplo: PARSE_PROMPT(prompt, clave=valor)).

```
1 def PARSE_PROMPT(BASE_PROMPT, **kwargs):  
2     for key in kwargs:  
3         BASE_PROMPT = BASE_PROMPT.replace(  
4             '{' + str(key) + '}',  
5             str(kwargs[key])  
6         )  
7     return BASE_PROMPT
```

Código 4: Utilidad de Procesado de Prompts

VIII.2) Pipeline de Extracción de Fuentes

Para extraer información procesada de fuentes autoritativas se procedió con el desarrollo de utilidades para extraer datos desde una URL (Código 5) y procesarlos en forma de *bullet points* para presentar los resultados de manera estructurada y clara (Código 7).

```
1 def extract_text_from_url(url: str) -> str:
2     headers = {
3         "User-Agent": "Mozilla/5.0 (X11; Linux x86_64; rv:140.0)
4         Gecko/20100101 Firefox/140.0",
5     }
6     response = requests.get(url, headers=headers).raise_for_status()
7     soup = BeautifulSoup(response.text, 'html.parser')
8     for tag in soup(['script', 'style']):
9         tag.decompose()
10
11     paragraphs = [p.get_text(strip=True) for p in soup.find_all('p')]
12     return '\n\n'.join(paragraphs)
```

Código 5: Scraper Extractor de Información

```
SOURCE_EXTRACTOR_PROMPT = """Eres un extractor de
información precisa y concisa. Tu tarea es leer el texto de
1 un artículo y devolver una lista de viñetas (•) con todos
2 los hechos y datos relevantes, escritos en español natural
3 y claro.
4 Instrucciones:
5 1. Identifica los hechos principales, cifras, declaraciones, fechas,
6 nombres y conclusiones clave del texto.
7 2. No incluyas opiniones, lenguaje publicitario o frases
8 irrelevantes.
9 3. Si el texto está en inglés u otro idioma, traduce los puntos al
10 español correctamente.
11 4. Usa frases breves pero completas, cada una iniciando con un punto
12 (•).
13 5. Mantén el tono informativo y objetivo.
14
15 Texto del artículo: {TEXT}
16 Tu respuesta: """
```

Código 6: Prompt de Extracción de Información

```

1  def extract_url_context(url):
2      text = extract_text_from_url(url)[:8_000]
3
4      completion = client.chat.completions.create(
5          model="openai/gpt-oss-120b",
6          messages=[{
7              "role": "user",
8              "content": [{
9                  "type": "text",
10                 "text": PARSE_PROMPT(SOURCE_EXTRACTOR_PROMPT,
11                                     TEXT=text)
12             }],
13             temperature=0,
14             max_completion_tokens=2048,
15             top_p=1,
16             stream=False,
17             stop=None,
18         )
19     content = completion.choices[0].message.content
20     return content

```

Código 7: Script de Extracción de Información

VIII.3) Generación de Contenido General

Para los metadatos generales de la plataforma, aunque no visibles en el **frontend** de la prueba de concepto, se pobló la base de datos con períodos, técnicas pictóricas y breves biografías de los autores. Estos proporcionan información contextual esencial para la interpretación y categorización de las obras de arte que en una etapa posterior del proyecto podrían enriquecer la experiencia del usuario con una base mas robusta de contenido. Pasa la generación de estos se usaron dos enfoques distintos. Para técnicas pictóricas y períodos artísticos, se empleó generación directa con modelos de lenguaje. En cambio, para biografías de autores se extrajo información de Wikipedia para evitar imprecisiones en datos biográficos complejos, priorizando la calidad de la fuente.

```

1  TECHNIQUE_PROMPT = \
2  """Explicame en detalle una técnica de pintura o dibujo.
3  Considera lo siguiente:
4  - Debe estar en un formato adecuado para narración.
5  - Debe ser conciso y corto en duración.
6  - NO digas en resumen.
7  - NO seas redundante.
8
9  - NO utilices títulos ni subtítulos, solo escribe en párrafos
10 narrados.
11
12 Técnica: {TECHNIQUE}
13 Explicación: """
14
15 def get_technique(technique):
16     completion = client.chat.completions.create(
17         #model="llama-3.1-8b-instant",
18         model="llama-3.3-70b-versatile",
19         messages=[{
20             "role": "user",
21             "content": [{
22                 "type": "text",
23                 "text": PARSE_PROMPT(TECHNIQUE_PROMPT,
24                                     TECHNIQUE=technique)
25             }]
26         }],
27         temperature=0,
28         max_completion_tokens=1024,
29         top_p=1,
30         stream=False,
31         stop=None,
32     )
33     content = completion.choices[0].message.content
34     return content

```

Código 8: Generador de Texto de Técnica

Como se ha detallado previamente, la generación de este contenido requiere únicamente el nombre de la técnica o estilo pictórico a describir. Además, se han implementado consideraciones específicas en cuanto a la cadencia y el estilo del texto generado, con el objetivo de optimizar su procesamiento mediante modelos de síntesis de voz (TTS).

```

1  PERIOD_PROMPT = \
2  """Explicame en detalle un estilo pictórico en particular.
3  Considera lo siguiente:
4  - Debe estar en un formato adecuado para narración.
5  - Debe ser conciso y corto en duración.
6  - NO digas en resumen.
7  - NO seas redundante.
8
9  - NO utilices títulos ni subtítulos, solo escribe en párrafos
10 narrados.
11
12 Estilo pictórico: {PERIOD}
13 Explicación: """
14
15 def get_period(period):
16     completion = client.chat.completions.create(
17         #model="llama-3.1-8b-instant",
18         model="llama-3.3-70b-versatile",
19         messages=[{
20             "role": "user",
21             "content": [{
22                 "type": "text",
23                 "text": PARSE_PROMPT(PERIOD_PROMPT, PERIOD=period)
24             }]
25         }],
26         temperature=0,
27         max_completion_tokens=1024,
28         top_p=1,
29         stream=False,
30         stop=None,
31     )
32     return completion.choices[0].message.content

```

Código 9: Generador de Texto de Período

En la generación de la biografía se utilizó un script de extracción de información (Código 7) para procesar un breve texto biográfico del autor.

```
1  AUTHOR_BIO_PROMPT = \
2  """Eres un experto en redacción biográfica y narrativa.
   Tu tarea es leer el siguiente texto y redactar una biografía breve y
3  fluida del autor o artista mencionado, adecuada para acompañar una
   ficha de obra de arte.
4  Instrucciones:
   1. Resume los aspectos esenciales de la vida y obra del autor:
5  formación, estilo, periodo histórico, aportes y relevancia artística.
   2. Mantén un tono natural, informativo y narrativo, sin usar listas
6  ni formato enciclopédico.
   3. Evita redundancias, tecnicismos innecesarios y frases genéricas.
7  4. No incluyas fechas o datos no presentes en el texto fuente.
   5. No menciones el proceso de redacción ni expresiones como "esta
8  biografía trata sobre".
   6. Si el texto está en otro idioma, tradúcelo al español de manera
9  natural.
10  7. Extensión máxima: dos párrafos.
11  8. Evita completamente el uso de caracteres especiales
12
13
14  Texto: {TEXT}
15  Tu respuesta: """
16
17  def get_bio(url):
18      text = extract_url_context(url)
19      completion = client.chat.completions.create(
20          model="llama-3.3-70b-versatile",
21          messages=[{
22              "role": "user",
23              "content": [{
24                  "type": "text",
25                  "text": PARSE_PROMPT(AUTHOR_BIO_PROMPT, TEXT=text)
26              }]
27          }],
28          temperature=0,
29      )
30      return completion.choices[0].message.content
```

Código 10: Author Bio Generation

VIII.4) Utilidades Generales de Procesamiento de Imágenes

A continuación, se definen utilidades de preprocesamiento general de imágenes que se aplican antes de realizar llamadas a proveedores de servicios de inferencia o de emplearlas en modelos autohospedados.

- **resize_if_oversized**: ajusta imágenes manteniendo proporciones, evitando que excedan un tamaño máximo para optimizar almacenamiento y rendimiento.
- **download_img**: descarga imágenes desde URLs usando un **user-agent** personalizado (para evitar bloqueos de conexión) y las redimensiona si superan el límite, garantizando su adaptación al sistema.
- **image_to_base64**: convierte imágenes PIL a base64, facilitando su transmisión y almacenamiento como texto plano para integración en APIs o bases de datos.

```
1  def resize_if_oversized(image, max_dim=1024):  
2      width, height = image.size  
3      if max(width, height) <= max_dim:  
4          return image # nothing to do  
5  
6      # scale preserving proportions  
7      scale = max_dim / max(width, height)  
8      new_size = (int(width * scale), int(height * scale))  
9      return image.resize(new_size, Image.Resampling.LANCZOS)  
10  
11 def download_img(url, max_dim: int = 1024):  
12     headers = { "User-Agent": "Chrome/51.0.2704.103 Safari/537.36" }  
13     r = requests.get(url, headers=headers)  
14     im = Image.open(BytesIO(r.content))  
15     im = resize_if_oversized(im, max_dim)  
16     return im  
17  
18 def image_to_base64(image: Image.Image, format="PNG") -> str:  
19     """Convert PIL Image to base64 string."""  
20     buffered = BytesIO()  
21     image.save(buffered, format=format)  
22     return base64.b64encode(buffered.getvalue()).decode("utf-8")
```

Código 11: Utilidades de Procesamiento de Imágenes

VIII.5) Generación de Audio Descriptivo

Este modulo toma como entrada una *URL* a una imagen, para luego procesarla en una descripción objetiva de los elementos representados.

Para el procesamiento de las imagenes se utilizan las utilidades definidas en Código 11.

Para la generación del texto se emplea un **prompt** estructurado que guía al modelo en la creación de descripciones del contenido representado utilizando una cadencia adecuada para su narración por voz.

```
1 DESCRIPTION_PROMPT = \
2 """Describe los elementos retratados en la imagen.
3 Considera lo siguiente:
4 - Debe estar en un formato adecuado para narración.
5 - Debe ser conciso y corto en duración.
6 - NO digas en resumen.
7 - NO seas redundante.
8   - NO utilices títulos ni subtítulos, solo escribe en parrafos
9   narrados.
10
11 Elementos retratados: """
12
13 def get_description(url):
14     image = download_img(url)
15     b64_image = image_to_base64(image)
16     completion = client.chat.completions.create(
17         model="meta-llama/llama-4-scout-17b-16e-instruct",
18         messages=[{
19             "role": "user",
20             "content": [
21                 { "type": "text",
22                   "text": DESCRIPTION_PROMPT },
23                 { "type": "image_url",
24                   "image_url": {
25                       "url": f"data:image/png;base64,{b64_image}"
26                   }
27             }
28         ]
29     },
30     temperature=0,
```

Código 12: Generación de texto para audios dsriptivos

VIII.6) Narrador de Contexto

Este modulo toma como entrada una *URL* de un articulo de Wikipedia para generar una narración didáctica sobre el contexto en que una obra se produjo.

Utiliza el módulo descrito en Código 7 para la extracción de la información.

```
1 SOURCE_SUMMARY_PROMPT = \ Python
    """Eres un experto en redacción narrativa. Tu tarea es leer el
2 siguiente texto y escribir un resumen breve (máximo dos párrafos) en
    un estilo natural, fluido y adecuado para narración oral o escrita.
3
4 Instrucciones:
    1. Mantén un tono narrativo, como si estuvieras contando los hechos
5 de manera clara y atractiva.
    2. Sé conciso: evita repeticiones, rodeos o frases innecesarias.
6
7    3. No incluyas títulos, subtítulos ni listas.
8
9    4. No uses expresiones como "en resumen", "este artículo trata
    sobre", ni menciones al proceso de resumen.
10
11    5. Si el texto está en otro idioma, tradúcelo al español con
    naturalidad.
12
13    6. Enfócate en los hechos principales y el contexto historico de la
    producción de la obra.
14
15 Texto: {TEXT}
16 Tu respuesta: """
17
18 def get_narration(url):
19     text = extract_url_context(url)
20     completion = client.chat.completions.create(
21         model="llama-3.3-70b-versatile",
22         messages=[{
23             "role": "user",
24             "content": [{
25                 "type": "text",
26                 "text": PARSE_PROMPT(SOURCE_SUMMARY_PROMPT,
27                                     TEXT=text)
28             }],
29             temperature=0,
30         )
31     ]
32     return completion.choices[0].message.content
```

Código 13: Generación de texto para narraciones

VIII.7) Generación de Sonidos Ambientales

La eurística utilizada para la generación de sonidos ambientales consiste en 3 pasos:

1. **Segmentación de la imagen** (Código 14): La obra se divide en cuadrantes mediante un algoritmo de particionamiento espacial. Cada cuadrante se utiliza posteriormente como entrada para los pasos posteriores.
2. **Extracción semántica de elementos** (Código 15): Mediante Llama 4 Scout 17B se analizan cada cuadrante para detectar objetos, seres vivos y elementos con potencial sonoro. La salida en JSON incluye descripción y clasificación (fondo/primer plano) de los elementos detectados.
3. **Síntesis de audio ambiental** (Código 16): Utilizando modelos generativos de audio basados en difusión (AudioLDM), se produce una composición sonora multicanal que integra los elementos detectados. Cada componente sonoro se ajusta en términos de volumen de acuerdo a si es categorizado como un objeto de fondo.

```
1  def get_quadrants(image: Image, N:int=3):  
2      total_width, total_height = image.size  
3      w, h = total_width//N, total_height//N  
4      w_pos = [(w*i, w*(i+1)) for i in range(N)]  
5      h_pos = [(h*i, h*(i+1)) for i in range(N)]  
6      boxes = [  
7          (w_pos[i][0], h_pos[j][0], w_pos[i][1], h_pos[j][1])  
8          for j in range(N) for i in range(N)  
9      ]  
10     cropped = [ image.crop(box)  
11                 for box in boxes ]  
12     coords= [  
13         ( (i/N + (i+1)/N)/2,  
14           (j/N + (j+1)/N)/2 )  
15         for j in range(N) for i in range(N)  
16     ]  
17  
18     return cropped, coords
```

Código 14: Segmentación de imagen en cuadrantes

```

1  EXTRACTOR_PROMPT = \
2  """Extract audio ambience generation keys from the following image.
3
4  Consider the following:
5  - Your output should be a list of json objects containing the keys:
6      {"is_background": bool, "object": string}
7  - Only indicate objects with sound ambience relevance.
8  - Ignore abstract elements
9  - Indicate 3 elements at most
10 - Group elements when there are more than 1 depicted
11 - You should only output ONE list
12   - Alive elements should be added with their corresponding sound
13     description (bear growling, dog barking)
14 - Non alive elements should be specified as the element itself
15 - Output just the required JSON results
16 JSON RESULT:"""
17
18 def get_semantic_elements(image: Image, max_attempts=3):
19     b64_image = image_to_base64(image)
20     for _ in range(max_attempts):
21         try:
22             completion = client.chat.completions.create(
23                 model="meta-llama/llama-4-scout-17b-16e-instruct",
24                 messages=[{
25                     "role": "user",
26                     "content": [
27                         { "type": "text",
28                           "text": EXTRACTOR_PROMPT },
29                         { "type": "image_url",
30                           "image_url": {
31                               "url": f"data:image/png;base64,{b64_image}" } }
32                     ]
33                 }],
34                 temperature=0,
35             )
36             content = completion.choices[0].message.content
37             return json.loads(content)
38         except:
39             continue
40     return []

```

Código 15: Extracción semántica de elementos en la obra

```

1  from diffusers import AudioLDMPipeline
2  from pydub import AudioSegment
3  import numpy as np
4  import tempfile
5  import os
6  import torch
7  VOLUME_DB_BACKGROUND = -20
8  VOLUME_DB_FOREGROUND = -5
9
10 pipe = AudioLDMPipeline.from_pretrained(
11     "cvssp/audioldm"
12     torch_dtype=torch.float16
13 ).to("cuda")
14
15 def tensor_to_audiosegment(audio_tensor, sample_rate=16000):
16     samples = (audio_tensor * 32767).astype(np.int16)
17     return AudioSegment(
18         samples.tobytes(),
19         frame_rate=sample_rate,
20         sample_width=2, # 16-bit = 2 bytes
21         channels=1
22     )
23
24 def generate_ambient_sound(scene, filename):
25     final_mix = AudioSegment.silent(duration=20000)
26     for i, obj in enumerate(scene):
27         prompt = obj['object']
28         negative_prompt = ["low quality, average quality"]
29         result = pipe(
30             [prompt],
31             negative_prompt=negative_prompt,
32             num_inference_steps=30,
33             audio_length_in_s=20,
34             return_dict=True
35         )
36         audio_tensor = result.audios[0].squeeze()
37         audio_segment = tensor_to_audiosegment(audio_tensor)
38         volume_db = VOLUME_DB_BACKGROUND if obj["is_background"] else
39             VOLUME_DB_FOREGROUND
40         audio_segment = audio_segment + volume_db
41         final_mix = final_mix.overlay(audio_segment)
42     final_mix.export(f"{filename}.wav", format="wav")

```

Código 16: Generación de sonido ambiental con AudioLDM

VIII.8) Text to Speech

Para el módulo de **Text-to-Speech** (TTS) se utilizó **Kokoro 82M** [21], para el cual existe una biblioteca en Python con módulos de inferencia preimplementados.

```
1 # !pip install -q kokoro>=0.9.4 soundfile
2 # !apt-get -qq -y install espeak-ng > /dev/null 2>&1
3
4 from kokoro import KPipeline
5 from IPython.display import display, Audio
6 import soundfile as sf
7 import torch
8
9 tts_pipeline = KPipeline(lang_code='e')
```

Código 17: Setup Kokoro TTS

Nuestra función de generación de TTS añade breves silencios entre párrafos para mantener una cadencia fluida en la narración.

```
1 def tts(text, filename):
2     generator = tts_pipeline(
3         text,
4         voice='em_santa',
5         speed=1, split_pattern=r'\n+'
6     )
7
8     pause_duration = 0.5
9     silence = np.zeros(int(24000 * pause_duration), dtype=np.float32)
10    all_audio = []
11
12    for i, (gs, ps, audio) in enumerate(generator):
13        all_audio.append(audio)
14        all_audio.append(silence)
15
16    final_audio = np.concatenate(all_audio)
17    sf.write(f"{filename}.wav", final_audio, 24000)
```

Código 18: Generación de audio con Kokoro TTS